

PRONÓSTICO
DE LA
DEMANDA DE KILOGRAMOS
DE CAFÉ DE
PEREGRINO CASA TOSTADORA

MARCO ESTEBAN SOBERANIS CETZ



Índice

OBJETIVO GENERAL	1
OBJETIVOS ESPECÍFICOS.....	1
RECOLECCIÓN DE DATOS HISTÓRICOS	2
ANÁLISIS DE LA SERIE DE TIEMPO DE PEREGRINO CASA TOSTADORA.....	5
Adaptación de la base de datos para que sea procesada en el programa R - Studio.....	5
Test de estacionariedad de la serie de tiempo de Peregrino Casa Tostadora.....	7
PRONÓSTICO DE LA DEMANDA DE CAFÉ EN KILOGRAMOS DE PEREGRINO CASA TOSTADORA	10
Criterios de decisión	10
Ajuste del modelo.....	10
Curva de normalidad	10
Errores del modelo	10
Método Naive considerando estacionariedad	11
Ajuste del modelo.....	11
Curva de normalidad	12
Errores del modelo	12
Pronóstico del modelo.....	13
Método Naive Simple	14
Ajuste del modelo.....	15
Curva de normalidad	15
Errores del modelo	15
Pronóstico del modelo.....	16
Método de Regresión	17
Ajuste del modelo.....	18
Curva de normalidad	18
Errores del modelo	18
Pronóstico del modelo.....	19
Método Holt Winters	20
Ajuste del modelo.....	21
Curva de normalidad	21
Errores del modelo	21
Pronóstico del modelo.....	22
CONCLUSIONES	23

OBJETIVO GENERAL

Calcular el pronóstico de la demanda de kilogramos de café en grano para los primeros tres meses de 2024 (enero, febrero y marzo) del negocio llamado Peregrino Casa Tostadora ubicado en Mérida Yucatán.

OBJETIVOS ESPECÍFICOS

- 1. Recolección de los datos históricos de un año*
- 2. Adaptación de la base de datos para que sea procesada en el programa R Studio*
- 3. Elaboración de los métodos de pronóstico*
- 4. Analizar los métodos de pronóstico*
- 5. Seleccionar los mejores métodos de pronóstico*
- 6. Comparar los mejores métodos de pronóstico*
- 7. Presentar los resultados*

RECOLECCIÓN DE DATOS HISTÓRICOS

El día 17 de enero de 2024 se hizo la recolección de los datos de la demanda de kilogramos mensual.

Formato de entrega de datos:

Pedido	Cliente	Clave	Factura	Kg	Descripción
01-ene-23	La Cejuda			5	Manos Sabias (Veracruz)
01-ene-23	La Cejuda			4	Manos Sabias (Veracruz)
01-ene-23	La Cejuda			6	Manos Sabias (Veracruz)
01-ene-23	La Cejuda			6	Manos Sabias (Veracruz)
01-ene-23	Louvre			2	2kg (8 bolsas de 250gr) tueste oscuro
01-feb-23	Baretto			2	Manos Sabias (Veracruz)
01-feb-23	Baretto			2	Manos Sabias (Veracruz)
01-feb-23	Baretto			2	Manos Sabias (Veracruz)
01-feb-23	Baretto			2	Manos Sabias (Veracruz)
01-feb-23	La Cejuda			4	Manos Sabias (Veracruz)
01-feb-23	La Cejuda			10	Manos Sabias (Veracruz)
01-feb-23	La Cejuda			6	Manos Sabias (Veracruz)
07-feb-23	ONZE			20	Manos Sabias (Veracruz)
10-feb-23	Louvre			2	2kg (8 bolsas, 4 blancas, 4 negras) tueste oscuro- molino
10-feb-23	Louvre			2	2kg (8 bolsas) tueste oscuro- molino
10-feb-23	Louvre			2	2kg en grano y 2kg molidos (8 bolsas de 250gr)
10-feb-23	ONZE			15	Manos Sabias (Veracruz)
10-feb-23	ONZE			15	Manos Sabias (Veracruz)
24-feb-23	La Cejuda			6	Manos Sabias (Veracruz)
27-feb-23	Louvre			4	4kg tueste oscuro
01-mar-23	CUCÚ	PEA-05		10	Manos Sabias (Veracruz)
01-mar-23	CUCÚ			10	Manos Sabias (Veracruz)
01-mar-23	La Cejuda			6	Manos Sabias (Veracruz)
01-mar-23	La Cejuda			5	Manos Sabias (Veracruz)
01-mar-23	Louvre			2	2kg en grano - Oscuro
13-mar-23	ONZE	PEA-01		10	Manos Sabias (Veracruz)
13-mar-23	ONZE	PEA-02		12	Manos Sabias (Veracruz)
13-mar-23	ONZE	PEA-03		15	Manos Sabias (Veracruz)
13-mar-23	ONZE	PEA-04		5	Manos Sabias (Veracruz)
19-mar-2023	ONZE	PEA-06		11	Manos Sabias (Veracruz)
20-mar-23	ONZE	PEA-07		5	Manos Sabias (Veracruz)
30-mar-23	Louvre			2	Manos Sabias (Veracruz)
30-mar-23	ONZE	PEA-08		4	Manos Sabias (Veracruz)
31-mar-23	ONZE	PEA-09		4	Manos Sabias (Veracruz)

10-abr-23	La Cejuda			6	Manos Sabias (Veracruz)
24-abr-23	La Cejuda			6	Manos Sabias (Veracruz)
24-abr-23	Louvre			4	Manos Sabias (Veracruz)
26-abr-23	ONZE	PEA-10		5	Manos Sabias (Veracruz)
30-abr-23	ONZE	PEA-11		3	Manos Sabias (Veracruz)
09-may-23	CUCÚ	PEA-13		5	Manos Sabias (Veracruz)
09-may-23	La Cejuda			6	Manos Sabias (Veracruz)
09-may-23	ONZE	PEA-12		20	Manos Sabias (Veracruz)
15-may-23	Baretto			2	Manos Sabias (Veracruz)
16-may-23	ONZE	PEA-14		5	Manos Sabias (Veracruz)
17-may-23	Louvre			2	Manos Sabias (Veracruz)
18-may-23	La Cejuda			5	Manos Sabias (Veracruz)
25-may-23	SERENO			3	Manos Sabias (Veracruz)
30-may-23	La Cejuda			3	Manos Sabias (Veracruz)
02-jun-23	Municipio M.	PEA-15		90	Manos Sabias (Veracruz)
05-jun-23	Baretto			2	Manos Sabias (Veracruz)
05-jun-23	Louvre			4	Manos Sabias (Veracruz)
09-jun-23	La Cejuda			4	Manos Sabias (Veracruz)
15-jun-23	SERENO			2	Marsellesa (Veracruz)
22-jun-23	Louvre			2	Marsellesa (Veracruz)
22-jun-23	SERENO			1	Marsellesa (Veracruz)
22-jun-23	SERENO			2	Marsellesa (Veracruz)
04-jul-23	Baretto			2	Marsellesa (Veracruz)
04-jul-23	ONZE	PEA-17		6	Manos Sabias (Veracruz)
04-jul-23	SERENO			2	Manos Sabias (Veracruz)
06-jul-23	ONZE	PEA-18		10	Manos Sabias (Veracruz)
13-jul-23	Baretto			2	Marsellesa (Veracruz)
13-jul-23	Louvre			2	Manos Sabias (Veracruz)
13-jul-23	Louvre			2	Manos Sabias (Veracruz)
13-jul-23	ONZE	PEA-19		6	Manos Sabias (Veracruz)
19-jul-23	SERENO			2	Manos Sabias (Veracruz)
26-jul-23	ONZE	PEA-20		10	Manos Sabias (Veracruz)
31-jul-23	Louvre			2	2kg (8 bolsas) tueste oscuro- molido
10-ago-23	Baretto			2	Grano de emergencia Sarchimor, Caturra, colombia (Costa rica)
10-ago-23	La Cejuda			10	Grano de emergencia Sarchimor, Caturra, colombia (Costa rica)
10-ago-23	SERENO			1	Manos Sabias (Veracruz) City
10-ago-23	SERENO			1	Manos Sabias (Veracruz) City
14-ago-23	SERENO			1	Grano de emergencia Sarchimor, Caturra, colombia (Costa rica)
14-ago-23	SERENO			2.5	Grano de emergencia Sarchimor, Caturra, colombia (Costa rica)
15-ago-23	Baretto			2	Grano de emergencia Sarchimor, Caturra, colombia (Costa rica)
23-ago-23	Louvre			2	2kg (8 bolsas) tueste oscuro- molido
24-ago-23	SERENO			4	Manos Sabias (Veracruz)
28-ago-23	Baretto			2	Manos Sabias
31-ago-23	La Cejuda			10	Manos Sabias (Veracruz)

07-sep-23	Baretto			2	Manos sabias
06-sep-23	SERENO			2.5	Manos Sabias (Veracruz)
06-sep-23	Louvre			2	2kg (8 bolsas) tueste oscuro- molido
11-sep-23	La Cejuda			10	Manos Sabias (Veracruz)
19-sep-23	SERENO			2.5	Manos Sabias (Veracruz)
11-sep-23	Baretto			2	Manos sabias
02-sep-23	Louvre			2	Manos Sabias (Veracruz) grano
19-sep-23	Baretto			2	Manos sabias
07-sep-23	Louvre			2	Manos Sabias (Veracruz) grano
25-sep-23	La Cejuda			10	Manos Sabias (Veracruz)
28-sep-23	SERENO			2.5	Manos Sabias (Veracruz)
02-oct-23	Louvre			1.750	Manos Sabias (Veracruz) grano
16-oct-23	La Cejuda			10	Neria, veracruz (San felipe) grano
19-sep-23	Baretto			2	Manos sabias
16-oct-23	Louvre			2	Neria, veracruz (San felipe) grano
15-oct-23	Baretto			4	Neria, veracruz (San felipe) grano
21-oct-23	Baretto			2	Manos sabias

Pedido	Cliente	Clave	Factura	Kg	Descripción
02-nov-23	Louvre			2	Chiapas
07-nov-23	Baretto			2	Manos sabias
07-nov-23	La Cejuda			10	San felipe
11-nov-23	Baretto			2	Manos sabias
15-nov-23	Louvre			2	Chiapas
17-nov-23	Baretto			2	Manos sabias
22-nov-23	Louvre			2	Chiapas
02-dic-23	Louvre			2	Chiapas
15-dic-23	Louvre			2	Chiapas
23-nov-23	Baretto			2	Manos sabias
23-nov-23	La Cejuda			5	Manos Sabias (Veracruz)
06-dic-23	Baretto			1.250	Neria, veracruz (San felipe) grano
18-dic-23	Baretto			2	Neria, veracruz (San felipe) grano
20-dic-23	Louvre			2	Chiapas

ANÁLISIS DE LA SERIE DE TIEMPO DE PEREGRINO CASA TOSTADORA

Adaptación de la base de datos para que sea procesada en el programa R - Studio

Reorganización de datos para trabajar en R-studio:

demanda por mes
23
94
101
24
51
107
46
37.5
39.5
21.75
29
9.25

Leemos la base de datos para con la información de la demanda mensual:

```
data<-read_xlsx("Serie de tiempo mensual de la demanda  
de café en grano de Peregrino Casa Tostadora copia.xlsx")
```

Visualizamos la base de datos en forma de tabla en R-Studio:

	demanda por mes
1	23.00
2	94.00
3	101.00
4	24.00
5	51.00
6	107.00
7	46.00
8	37.50
9	39.50
10	21.75
11	29.00
12	9.25

Obtenemos información básica de la base de datos con el comando Summary


```
> summary(data)
demanda por mes
Min.   : 9.25
1st Qu.: 23.75
Median : 38.50
Mean   : 48.58
3rd Qu.: 61.75
Max.   :107.00
```

Lo **mínimo** vendido por mes fueron **9.25 kg** en el 12avo mes (**Diciembre**)

Lo **máximo** vendido por mes fueron **107 kg** en el 6to mes (**Junio**)

El **promedio** vendido por mes es de **48.58 kg**

Presentación gráfica de la demanda en kilogramos de café:



La gráfica representa la **demanda mensual agrupadas en los cuatro trimestres** del año 2023.

De igual manera nos permite observar que los datos se comportan de forma **aleatoria** por lo que procedemos a realizar una prueba de estacionalidad.

Test de estacionariedad de la serie de tiempo de Peregrino Casa Tostadora

```
> adf.test(Peregrino_TimeSeries)
```

Augmented Dickey-Fuller Test

```
data: Peregrino_TimeSeries
Dickey-Fuller = -1.1096, Lag order = 2, p-value = 0.9045
alternative hypothesis: stationary
```

El P-Value es mayor que 0.05 por lo que:


Se acepta la hipótesis nula: La serie de tiempo **no es estacionaria**

Cuando una serie de tiempo no es estacionaria significa que **los datos no siguen un patrón de comportamiento** y que la demanda de kilogramos de café cambió a lo largo del tiempo por lo que **dificulta la predicción** de la demanda esperada en el primer trimestre del año 2024.

Descomposición de la serie de tiempo de Peregrino Casa Tostadora

Descomponemos nuestra serie para obtener pronósticos más precisos.


```
fit<-decompose(Peregrino_TimeSeries)
```



El gráfico “**trend**” muestra la **tendencia** del comportamiento de los datos mensuales a lo largo del año 2023

La **tendencia** de **Peregrino Casa Tostadora** sigue un patrón **decreciente**. Esto quiere decir que las ventas, tomando en cuenta toda la serie de tiempo, fueron bajando.


Gráfico de la serie de tiempo con su tendencia



El gráfico “**seasonal**” muestra de forma exagerada el **patrón de estacionariedad trimestral** que siguen los datos a lo largo del 2023.

Como pudimos ver gráficamente y por medio de la prueba de estacionariedad, sabemos que nuestra serie de tiempo no sigue un patrón trimestral, esto quiere decir que **las ventas cambian según el trimestre que se esté cursando**.

Gráfico de estacionariedad



Como podemos observar este gráfico nos comprueba que no existe un patrón trimestral por lo que dependiendo del trimestre que estemos cursando las ventas se comportaran de manera diferente.

PRONÓSTICO DE LA DEMANDA DE CAFÉ EN KILOGRAMOS DE PEREGRINO CASA TOSTADORA

Criterios de decisión

Ajuste del modelo

Se analizará gráficamente el ajuste del pronóstico en comparación con la demanda real para determinar si es un buen modelo de pronóstico.

Curva de normalidad

Si los residuales están agrupados dentro de la curva de normalidad esto quiere decir que nuestro modelo de pronóstico es mejor para predecir la demanda con mayor precisión.

Errores del modelo

Error cuadrático medio (RMSE): Entre más próximo a 0 indica un ajuste mejor del modelo de pronóstico.

Error absoluto medio (MAE): Entre más próximo a 0 indica un ajuste mejor del modelo de pronóstico.

Error porcentual medio absoluto (MAPE): Entre más próximo a 0 indica un ajuste mejor del modelo de pronóstico.


Método Naive considerando estacionariedad

Código:

```
m1 <- snaive(Peregrino_TimeSeries, h=3)

#verificando el ajuste del método
autoplot(m1)+autolayer(fitted(m1), series="Ajuste")
```

Gráfico del pronóstico con su ajuste:




Al analizar la gráfica se observa que el pronóstico para el primer trimestre del 2024 va a ser igual al último trimestre del 2023. Esto se debe al modelo del pronóstico que se está usando y no necesariamente es algo malo hasta que se analiza su ajuste, su curva de normalidad y sus errores.

Ajuste del modelo

El ajuste del método, a simple vista, no se adecúa a los datos reales de la demanda por lo que no parece ser un buen modelo de pronóstico.

Curva de normalidad



Los datos no se ven desordenados y si bien los datos no están es su totalidad agrupados dentro de la curva de normalidad parece tener una distribución aceptable por lo que este modelo de pronóstico puede ser bueno para conocer la futura demanda.

Errores del modelo

ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
-17.55556	31.06244	24	-77.9368	90.73685	1	-0.003908617

RMSE = 31.06

MAE = 24

MAPE = 90.73%

Los **errores** son **medianamente altos** por lo que **no parece ser el mejor modelo** para nuestro pronóstico.

Pronóstico del modelo**Forecasts:**

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
5.000000	21.75	-18.05811	61.55811	-39.13126	82.63126
5.333333	29.00	-10.80811	68.80811	-31.88126	89.88126
5.666667	9.25	-30.55811	49.05811	-51.63126	70.13126

La **demanda esperada** para el mes de **enero** es de:

21.75 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 82.63 kg**

La **demanda esperada** para el mes de **febrero** es de:

29.00 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 89.88 kg**

La **demanda esperada** para el mes de **marzo** es de:

9.25 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 70.13 kg**


Método Naive Simple

Código:

```
#MÉTODO NAIVE SIMPLE
m1.1 <- naive(Peregrino_TimeSeries, h=3)

#verificando el ajuste del método
autoplot(m1.1)+autolayer(fitted(m1.1), series="Ajuste")
```

Gráfico del pronóstico con su ajuste:




El gráfico muestra al pronóstico como una línea horizontal por lo que la demanda en enero va a ser la misma que en febrero y, por lo tanto, también en marzo, al mismo tiempo, es igual al último registro de la demanda real. Una línea horizontal no significa un mal pronóstico, y, en este caso, no podemos ignorar este modelo de pronóstico ya que el p - value es menor que 0.05 lo que nos indica que tenemos un buen modelo de pronóstico.

Ajuste del modelo

El ajuste del modelo no es el deseado visualmente, se puede decir que está medianamente ajustado a la demanda real, sin embargo, hay puntos en la serie de tiempo que tienen una diferencia significativa.

Curva de normalidad



Se observa que los datos no se agrupan dentro de la curva de normalidad como se desea, pero a pesar de eso, parece adecuarse a la forma de la curva por lo que podría considerarse un buen modelo de pronóstico.

Errores del modelo

ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
-1.25	42.03779	32.20455	-50.31163	89.91227	1.341856	-0.2015105

RMSE = 42.03

MAE = 32.20

MAPE = 89.91%

Los **errores** son **altos** por lo que **no parece un modelo adecuado** para nuestro pronóstico.

Pronóstico del modelo

Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
9.25	-44.62360	63.12360	-73.14256	91.64256
9.25	-66.93878	85.43878	-107.27068	125.77068
9.25	-84.06181	102.56181	-133.45810	151.95810

La **demanda esperada** para el mes de **enero** es de:

9.25 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 91.64 kg**

La **demanda esperada** para el mes de **febrero** es de:

9.25 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 125.77 kg**

La **demanda esperada** para el mes de **marzo** es de:

9.25 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 151.95 kg**

Método de Regresión


Código:

```
# elaborando la regresion
regresion <- tslm(Peregrino_TimeSeries ~ trend + season)

# elaborando el pronostico
m2 <- forecast(regresion, h=3)

# verificando el ajuste del método
autoplot(m2)+autolayer(fitted(m2), series="Ajuste")
```

Gráfico del pronóstico con su ajuste:




El gráfico muestra el **primer punto** del pronóstico en **números negativos** y por esa razón se va a tomar en cuenta que **la demanda de café va a estar en 0 kg**.

Ajuste del modelo

El ajuste del modelo es bastante bueno ya que **la proximidad entre el pronóstico y la demanda es cercana** por lo que tenemos un **ajuste deseado** y se puede decir que **este modelo es el mejor** comparado con los últimos dos.

Curva de normalidad



Se observa que los datos están **dentro de la curva de normalidad** y se **adaptan bastante bien a los límites de la curva** por lo que podemos seguir diciendo que este es el mejor modelo hasta ahora para pronosticar la demanda de kilogramos de café para el primer trimestre de 2024.

Errores del modelo

ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
-5.62513e-15	20.38017	17.875	-30.58761	66.30743	0.7447917	-0.03850359

RMSE = 20.38

MAE = 17.87

MAPE = 66.30%

Los **errores** son **medianamente bajos** por lo que **este es de los mejores modelos** para nuestro pronóstico hasta ahora.

Pronóstico del modelo

Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
-15.729167	-60.73997	29.28163	-90.03755	58.57922
8.458333	-36.55247	53.46913	-65.85005	82.76672
19.770833	-25.23997	64.78163	-54.53755	94.07922

La **demanda esperada** para el mes de **enero** es de:

0 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 58.57 kg**

La **demanda esperada** para el mes de **febrero** es de:

8.45 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 82.76 kg**

La **demanda esperada** para el mes de **marzo** es de:

19.77 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 94.07 kg**


Método Holt Winters

Código:

```
# elaborando el pronostico
m3 <- hw(Peregrino_TimeSeries, h=3, seasonal = 'multiplicative')

# verificando el ajuste del método
autoplot(m3)+autolayer(fitted(m3), series="Ajuste")
```


Gráfico del pronóstico con su ajuste:



Ajuste del modelo

Visualmente, **el ajuste del modelo es mejor que el de los primeros modelos de pronóstico** (Método Naive considerando estacionariedad y Método Naive Simple), sin embargo, **no es igual de bueno que el del método de Regresión**. Podemos decir que **el Método Holt Winters es un buen modelo de pronóstico** para conocer la demanda del primer trimestre de 2024.

Curva de normalidad



Los datos se agrupan dentro de la curva de normalidad en su mayoría, es por eso que podemos decir que **tenemos un buen modelo de pronóstico**, sin embargo, el modelo que mejor se adecúa a la curva de normalidad es el de Regresión.

Errores del modelo

ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
-4.68847	20.26481	17.93656	-52.65454	68.74838	0.7473566	0.1235822

RMSE = 20.26

MAE = 17.93

MAPE = 68.74%

Los **errores** son **medianamente bajos** por lo que **este es de los mejores modelos** para nuestro pronóstico compitiendo directamente con el método de Regresión.

Pronóstico del modelo

Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
16.95870	3.622585	30.29481	-3.437128	37.35453
24.75489	5.225877	44.28390	-5.112156	54.62193
25.99499	5.253080	46.73690	-5.727025	57.71701

La **demanda esperada** para el mes de **enero** es de:

16.95 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 37.35 kg**

La **demanda esperada** para el mes de **febrero** es de:

24.75 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 54.62 kg**

La **demanda esperada** para el mes de **marzo** es de:

25.99 kg

Podemos decir con un **95% de confianza** que la demanda va a estar entre **0.00 kg y 57.71 kg**

CONCLUSIONES

Se debe de prestar más atención al Método de Regresión y al Método Holt Winters ya que sus errores son parecidos entre sí y al mismo tiempo son más cercanos a cero. Los errores de un pronóstico son tomados en cuenta como un criterio de decisión primordial cuando se trata de modelos de pronóstico y como los modelos seleccionados tienen errores que se parecen entre sí no nos permite decantarnos por uno.

Tomando en cuenta el criterio de datos agrupados dentro de los límites de la curva de normalidad es mejor el método de regresión ya que muestra una distribución más adecuada a lo normal por lo que se obtiene un pronóstico más preciso.

Como recomendación final se debería dar seguimiento a la demanda real para el primer trimestre del 2024 para luego ser comparada con los dos mejores modelos de pronóstico para poder prever la demanda que se espera en el futuro.

Hoy recomiendo que se tomen en cuenta los dos modelos con sus rangos de demanda esperada al 95% de confianza sin llegar al límite superior de ese rango para poder ahorrar en costos de producción y evitar la sobreproducción.